

COURSE TERM PROJECT

Week 14 Checkpoint

Team:水色真珠音調~用閃亮的歌聲開始現場演唱

組長/組員：廖祥恩

team_project 主題與目標

主題

透過類似 AI 議會的方式，讓檢測一筆資安球資可以透過多個 AI 協作分析，最後輸出結果。

動機

由於最近發現有種決策機制是透過三個 AI 投票決定，像是過去知名動漫《新世紀福音戰士》中的”MAGI”般，十分酷炫。因此，我好奇這樣的決策機制是否有助於資安情資的分類，這樣的效果又是如何。

然而，由於技術與時間壓力，原本打算使用三種不同的模型作為 AI 議會的委員進行投票，因此簡化成同一個 AI 不同的 finetuning 資料搭配 system prompt 進行。而可行性的部分，我認為若我們透過不同的資料集進行訓練，可以達成一定程度的視角獨立，但是因為還是同一個 base model 所以可能對於某些方面的 AI 情資還是會造成依定的偏見。

預期進行方式

Step 0 前置準備：準備資料集與測試集

Step 1 挑選 gemma 3 作為 baseline model 進行微調，並用測試句子集進行測試，觀察其表現。

Step 2 Gemma3 搭配 LoRA adapter 與 system prompt 進行微調作為實驗組，並用相同的測試集做為測試。

Step 3 最後比較 AI 多個 agents 協調出來的結果有沒有比較好。

Baseline 和計畫實驗的關係表格

	Model	Data	System prompt
Baseline	Gemma 3	完整資安事件資料，不區分角色，全部一次丟入	單一通用 prompt，沒有角色區分

Multi agents	Gemma3（共用 base，三個 LoRA adapter）	依角色切割： Analyst 看 raw logs、Hunter 看摘要 + RAG、Auditor 看前兩者輸出	三個獨立 system prompt，各自定義 Analyst / Hunter / Auditor 角色
--------------	---------------------------------	--	---

資料集

資料集介紹

本專題選定 CIC-IDS2017 作為實驗資料集，並透過 Hugging Face 下載。CIC-IDS2017 由加拿大網路安全研究院（Canadian Institute for Cybersecurity）於 2017 年建立，包含五天（7 月 3 日至 7 日）的真實網路流量記錄，涵蓋正常流量與多種攻擊類型，例如 Web Attacks、DDoS、Brute Force 等，共計 135,000 筆事件、79 個特徵欄位。

本研究從中選取 Thursday Morning Web Attacks 子集進行實驗，該子集包含 SQL Injection、XSS 及 Brute Force 三類攻擊，攻擊樣本與正常流量並存，適合作為多代理分析系統的輸入來源。

之後，我們將把這筆資料分割為三份，分別對應三個 agent 的不同資訊視角：Analyst agent 接收原始網路流量特徵、Hunter agent 接收 Analyst 的摘要輸出並搭配 RAG 查詢 MITRE ATT&CK 威脅情資、Auditor agent 則僅接收前兩者的推論結果並進行審查與質疑。此資訊切割設計是本系統的核心設計貢獻，使三個共用相同 base model 的 agent 能夠產生真正不同的推理路徑。

下載與簡單分析資料集

```
1 from datasets import load_dataset
2 import pandas as pd
3
4 # 直接读进 pandas, 不用手动下载
5 ds = load_dataset('c0ldsnap/CIC-IDS2017',
6                   data_files='Thursday-WorkingHours-Morning-WebAttacks.pcap_ISCX.csv',
7                   split='train')
8 df = ds.to_pandas()
```

```
1 print(df.shape)
2 print(df.columns.tolist())
3 print(df.head(5))
4 print(df['Label'].value_counts())
```

```
... (170366, 79)
```

	Destination Port	Flow Duration	Total Fwd Packets \
0	389	113095465	48
1	389	113473706	68
2	0	119945515	150
3	443	60201928	9
4	53	269	2

	Total Backward Packets	Total Length of Fwd Packets \
0	24	9668
1	40	11364
2	0	0
3	7	2330
4	2	102

	Total Length of Bwd Packets	Fwd Packet Length Max \
0	10012	403
1	12718	403
2	0	0
3	4221	1093
4	322	51

	Fwd Packet Length Min	Fwd Packet Length Mean	Fwd Packet Length Std \
--	-----------------------	------------------------	-------------------------

資料及全貌 1

1 df

	Destination Port	Flow Duration	Total Fwd Packets	Total Backward Packets	Total Length of Fwd Packets	Total Length of Bwd Packets	Fwd Packet Length Max	Fwd Packet Length Min	Fwd Packet Length Mean	Fwd Packet Length Std	...	min_seg_size_forward	Active Mean	Active Std	Active Max	Active Min	Idle
0	389	113095465	48	24	9668	10012	403	0	201.416657	203.548293	...	32	203985.500	5.758373e+05	1629110	379	13800
1	389	113473706	68	40	11364	12718	403	0	167.117647	171.919413	...	32	178326.875	5.034269e+05	1424245	325	13800
2	0	119945515	150	0	0	0	0	0	0.000000	0.000000	...	0	6909777.333	1.170000e+07	20400000	6	24400
3	443	60261928	9	7	2330	4221	1093	0	258.888889	409.702161	...	20	0.000	0.000000e+00	0	0	
4	53	269	2	2	102	322	51	51	51.000000	0.000000	...	32	0.000	0.000000e+00	0	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
170361	55641	49	1	3	6	18	6	6	6.000000	0.000000	...	20	0.000	0.000000e+00	0	0	
170362	45337	217	2	1	31	6	31	0	15.500000	21.920310	...	32	0.000	0.000000e+00	0	0	
170363	22	1387547	41	46	2728	6634	456	0	66.536585	110.129945	...	32	0.000	0.000000e+00	0	0	
170364	22	207	1	1	0	0	0	0	0.000000	0.000000	...	32	0.000	0.000000e+00	0	0	
170365	60146	50	1	2	0	0	0	0	0.000000	0.000000	...	32	0.000	0.000000e+00	0	0	

170366 rows x 79 columns

資料及全貌 2

Total Length of Fwd packets	Total Length of Bwd Packets	Fwd Packet Length Max	Fwd Packet Length Min	Fwd Packet Length Mean	Fwd Packet Length Std	...	min_seg_size_forward	Active Mean	Active Std	Active Max	Active Min	Idle Mean	Idle Std	Idle Max	Idle Min	Label
9668	10012	403	0	201.416667	203.548293	...	32	203985.500	5.758373e+05	1629110	379	13800000.0	4.277541e+06	16500000	6737603	BENIGN
11364	12718	403	0	167.117647	171.919413	...	32	178326.875	5.034269e+05	1424245	325	13800000.0	4.229413e+06	16500000	6945512	BENIGN
0	0	0	0	0.000000	0.000000	...	0	6909777.333	1.170000e+07	20400000	6	24400000.0	2.430000e+07	60100000	5702188	BENIGN
2330	4221	1093	0	258.888889	409.702161	...	20	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
102	322	51	51	51.000000	0.000000	...	32	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
6	18	6	6	6.000000	0.000000	...	20	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
31	6	31	0	15.500000	21.920310	...	32	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
2728	6634	456	0	66.536585	110.129945	...	32	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
0	0	0	0	0.000000	0.000000	...	32	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN
0	0	0	0	0.000000	0.000000	...	32	0.000	0.000000e+00	0	0	0.0	0.000000e+00	0	0	BENIGN

分割資料集

為了實現多代理議會的核心設計，本研究將 CIC-IDS2017 資料集依照三個代理的角色，設計差異化的資訊輸入視角。**Analyst Agent** 接收原始網路流量行為特徵，包含 TCP flag 統計、flow count、port 等欄位，負責描述「事件發生了什麼」；**Hunter Agent** 則接收封包長度統計與 window size 等高層次流量模式特徵，並搭配 RAG 查詢 MITRE ATT&CK 威脅情資，負責建立攻擊假設；**Auditor Agent** 不直接讀取原始資料欄位，而是在 pipeline 執行時接收 Analyst 與 Hunter 的推論輸出，專門負責審查兩者的邏輯漏洞與不確定假設，並給出修正後的信心分數。最終由 **Judge Agent** 整合三方結論，輸出最終威脅分類與應變建議。

此資訊切割設計確保三個代理的推理路徑真正分叉，即使共用相同的 **base model**，也能產生來自不同視角的分析結果，是本系統區別於單一 LLM 方法的核心貢獻。

架構圖



分割資料

```
1 import pandas as pd
2
3 # 先清空
4 df.columns = df.columns.str.strip()
5
6 # --- Analyst 視角: 根據行為特徵 (最原始的觀察層)
7 analyst_cols = [
8     "Destination Port", "Flow Duration",
9     "Total Fwd Packets", "Total Backward Packets",
10    "Flow Bytes/s", "Flow Packets/s",
11    "FIN Flag Count", "SYN Flag Count", "RST Flag Count",
12    "ACK Flag Count", "PSH Flag Count",
13    "Label"
14 ]
15 df_analyst = df[analyst_cols].copy()
16
17 # --- Hunter 視角: 封包統計特徵 (更高層次的模式)
18 hunter_cols = [
19     "Flow Duration",
20     "Fwd Packet Length Max", "Fwd Packet Length Min", "Fwd Packet Length Mean",
21     "Bwd Packet Length Max", "Bwd Packet Length Min", "Bwd Packet Length Mean",
22     "Packet Length Mean", "Packet Length Std", "Packet Length Variance",
23     "Average Packet Size",
24     "Down/Up Ratio",
25     "Init_Win_bytes_forward", "Init_Win_bytes_backward",
26     "Label"
27 ]
28 df_hunter = df[hunter_cols].copy()
29
30 # --- 確認
31 print("Analyst view:", df_analyst.shape)
32 print(df_analyst.head(3))
33
34 print("\nHunter view:", df_hunter.shape)
35 print(df_hunter.head(3))
36
37 print("\nLabel distribution:")
38 print(df["Label"].value_counts())
```

```
31 print("Analyst view:", df_analyst.shape)
32 print(df_analyst.head(3))
33
34 print("\nHunter view:", df_hunter.shape)
35 print(df_hunter.head(3))
36
37 print("\nLabel distribution:")
38 print(df["Label"].value_counts())

***
Analyst view: (170390, 12)
Destination Port  Flow Duration  Total Fwd Packets  Total Backward Packets \
0      389      113095465           48           24
1      389      113473706           68           40
2       0      119945515          150           0

Flow Bytes/s  Flow Packets/s  FIN Flag Count  SYN Flag Count \
0      174.01282      0.636030           0           1
1      212.225377      0.951762           0           1
2       0.000000      1.250568           0           0

RST Flag Count  ACK Flag Count  PSH Flag Count  Label
0           0           1           0  BENIGN
1           0           1           0  BENIGN
2           0           0           0  BENIGN

Hunter view: (170390, 14)
Flow Duration  Fwd Packet Length Max  Fwd Packet Length Min \
0      113095465           483           0
1      113473706           403           0
2      119945515           0           0

Fwd Packet Length Mean  Bwd Packet Length Max  Bwd Packet Length Mean \
0      201.416667           923      417.166667
1      167.117647          1139      317.950000
2       0.000000           0      0.000000

Packet Length Mean  Packet Length Std  Packet Length Variance \
0      276.109589      233.833248      54677.98782
1      224.633027      198.999612      39600.84557
2       0.000000      0.000000      0.000000

Average Packet Size  Down/Up Ratio  Init_Win_bytes_forward \
0      278.930596           0           571
```

```
1      212.225377      0.951762           0           1
2       0.000000      1.250568           0           0

RST Flag Count  ACK Flag Count  PSH Flag Count  Label
0           0           1           0  BENIGN
1           0           1           0  BENIGN
2           0           0           0  BENIGN

Hunter view: (170390, 14)
Flow Duration  Fwd Packet Length Max  Fwd Packet Length Min \
0      113095465           483           0
1      113473706           403           0
2      119945515           0           0

Fwd Packet Length Mean  Bwd Packet Length Max  Bwd Packet Length Mean \
0      201.416667           923      417.166667
1      167.117647          1139      317.950000
2       0.000000           0      0.000000

Packet Length Mean  Packet Length Std  Packet Length Variance \
0      276.109589      233.833248      54677.98782
1      224.633027      198.999612      39600.84557
2       0.000000      0.000000      0.000000

Average Packet Size  Down/Up Ratio  Init_Win_bytes_forward \
0      278.930596           0           571
1      226.712963           0           390
2       0.000000           0          -1

Init_Win_bytes_backward  Label
0           2079  BENIGN
1           2081  BENIGN
2            -1  BENIGN

Label distribution:
Label
BENIGN      168136
Web Attack  ◆ Brute Force      1507
Web Attack  ◆ XSS              652
Web Attack  ◆ Sql Injection     21
Name: count, dtype: int64
```

Analysis 資料

1 df_analyst

	Destination Port	Flow Duration	Total Fwd Packets	Total Backward Packets	Flow Bytes/s	Flow Packets/s	FIN Flag Count	SYN Flag Count	RST Flag Count	ACK Flag Count	PSH Flag Count	Label
0	389	113095465	48	24	1.740123e+02	0.636630	0	1	0	1	0	BENIGN
1	389	113473706	68	40	2.122254e+02	0.951762	0	1	0	1	0	BENIGN
2	0	119945515	150	0	0.000000e+00	1.250568	0	0	0	0	0	BENIGN
3	443	60261928	9	7	1.087088e+02	0.265508	0	0	0	0	1	BENIGN
4	53	269	2	2	1.576208e+06	14869.888480	0	0	0	0	0	BENIGN
...	...	...	...	...	...	...	...	...	...	...	...	...
170361	55641	49	1	3	4.897959e+05	81632.653060	1	0	0	0	0	BENIGN
170362	45337	217	2	1	1.705069e+05	13824.884790	0	1	0	1	0	BENIGN
170363	22	1387547	41	46	6.747159e+03	62.700579	0	0	0	0	1	BENIGN
170364	22	207	1	1	0.000000e+00	9661.835749	0	0	0	1	0	BENIGN
170365	60146	50	1	2	0.000000e+00	60000.000000	0	0	0	1	0	BENIGN

170366 rows x 12 columns

Hunter 資料

1 df_hunter

	Flow Duration	Fwd Packet Length Max	Fwd Packet Length Min	Fwd Packet Length Mean	Bwd Packet Length Max	Bwd Packet Length Mean	Packet Length Mean	Packet Length Std	Packet Length Variance	Average Packet Size	Down/Up Ratio	Init_Win_bytes_forward	Init_Win_bytes_backward	Label
0	113095465	403	0	201.416667	923	417.166667	275.109589	233.833248	54677.987820	278.930556	0	571	2079	BENIGN
1	113473706	403	0	167.117647	1139	317.950000	224.633027	198.999612	39600.845570	226.712963	0	390	2081	BENIGN
2	119945515	0	0	0.000000	0	0.000000	0.000000	0.000000	0.000000	0.000000	0	-1	-1	BENIGN
3	60261928	1093	0	258.888889	1460	603.000000	385.352941	532.094087	283124.117600	409.437500	0	8192	513	BENIGN
4	269	51	51	51.000000	161	161.000000	95.000000	60.249481	3630.000000	118.750000	1	-1	-1	BENIGN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
170361	49	6	6	6.000000	6	6.000000	6.000000	0.000000	0.000000	7.500000	3	0	0	BENIGN
170362	217	31	0	15.500000	6	6.000000	17.000000	16.350331	267.333333	22.666667	0	137	0	BENIGN
170363	1387547	456	0	66.536585	976	144.217391	106.386364	237.174480	56251.734060	107.609195	1	29200	243	BENIGN
170364	207	0	0	0.000000	0	0.000000	0.000000	0.000000	0.000000	0.000000	1	290	243	BENIGN
170365	50	0	0	0.000000	0	0.000000	0.000000	0.000000	0.000000	0.000000	2	243	290	BENIGN

170366 rows x 14 columns

參考資料

資料集：

[/CIC-IDS2017](#)

[Thursday-WorkingHours-Morning-WebAttacks.pcap_ISCX.csv](#)

參考論文：

- Du et al., 2023 — Improving Factuality and Reasoning in Language Models through Multiagent Debate，[arXiv: 2305.14325](#)，發表於 **ICML 2024**